

Tour Version



Data Mining


Tour 4

Classification

Classification

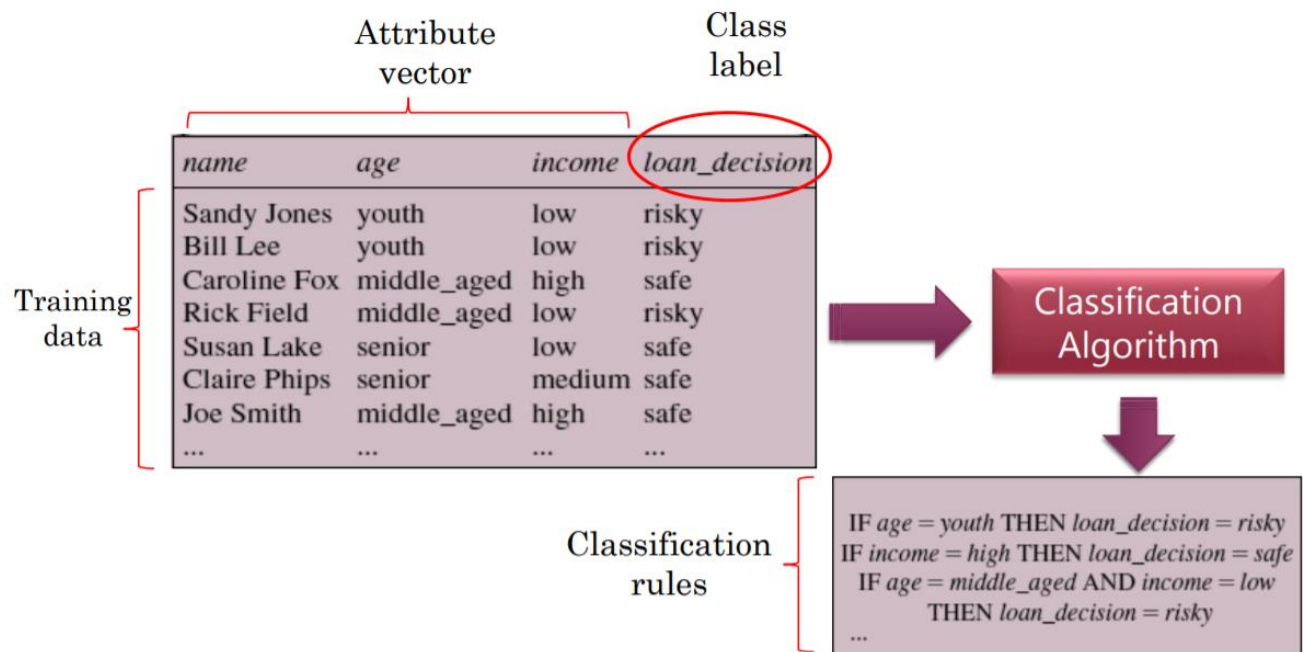
What is The Classification

- Classification is a data analysis task where a model is constructed to predict class labels (categories)
- Motivation: Prediction
- المحرك الأساسي للتصنيف هو التنبؤ رغم الأغراض الثانية زى التوصيف للبيانات
- **Descriptive vs Predictive Tasks** Chapter 1
- Is a bank loan applicant “safe” or “risky”?
- يكون متعلم من البيانات اللى فانت هل مثلا الشخص بالامكانيات المتاحة هل هيكون اقتراضه آمن او خطر
- Which treatment is better for patient, “treatmentX” or “treatmentY”?

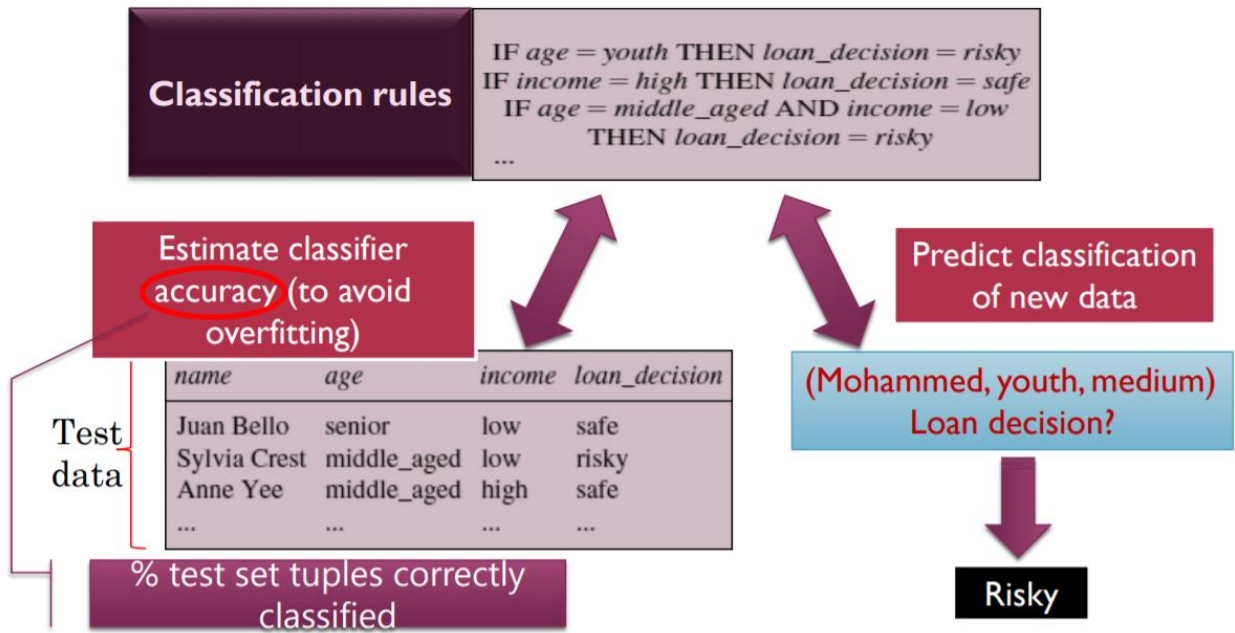


two-step process

1. Learning (training) step → construct classification model
 - Build classifier for a predetermined set of classes
 - Learn from a training dataset (data tuples + their associated classes) → Supervised Learning
 - طبعا دى محتاجة داتا عشان يتدرب عليها و هنا بيدخل دور ال
 - Machine learning
2. Classification step → model is used to predict class labels for given data (test set)



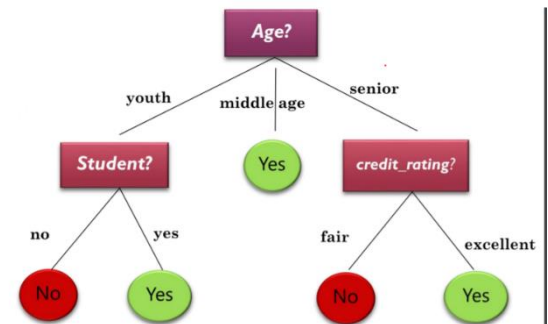
- يحتاج داتا يتدرب عليها فيصنع مودل عبارة عن مجموعة من القواعد عن طريق الجوريزم معين
- Age and Income is the attributes that can judge about loan

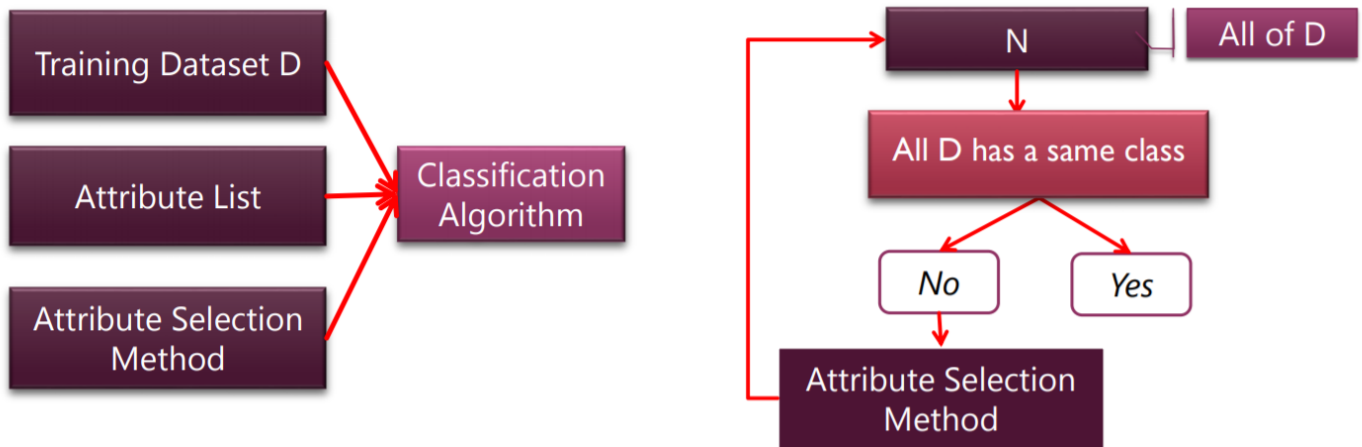


- بعد ما يطلع القواعد بنختبر مدى دقة المودل ده عن طريق انى بجيب داتا تانية بختبر عليها مدى صحة القواعد دى
- و ان كان مدى دقة القواعد سليمة كفاية ,, منكم انتبأ لو فيه داتا من غير تصنيف اقدر اصنفها بالقواعد دى

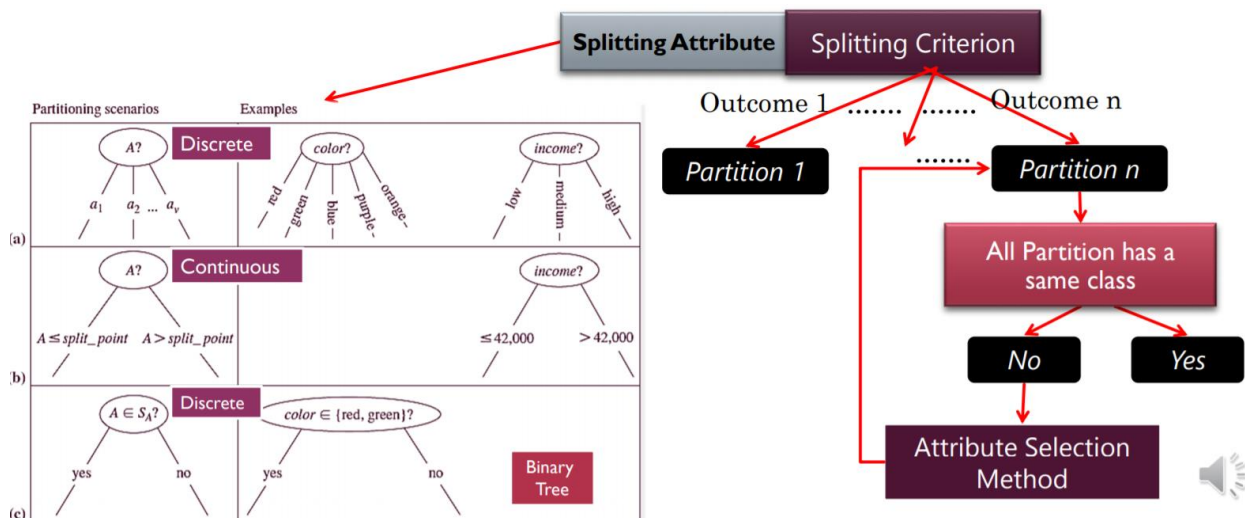
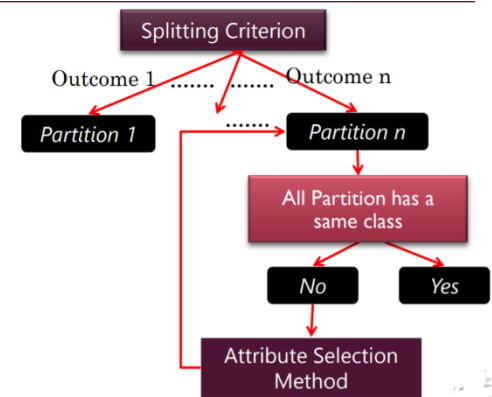
Decision Tree Induction

- Learning of decision trees from training dataset
- Decision tree → A flowchart-like tree structure
 - Internal node → a test on an attribute
 - Branch → a test outcome
 - Leaf node → a class label
- Constructed tree can be binary or otherwise
- Benefits
 - No domain knowledge required
 - No parameter setting
 - Can handle multidimensional data
 - Easy-to-understand representation
 - Simple and fast





- عشان نعمل التصنيف محتاجين نعرف 3 حاجات هي ايه الداتا اللي هندرب بيها المودل و ايه هي مجموعة الأعمدة او الخصائص اللي هيتم عليهم الاختبار و ايه هي الطريقة او الميثود اللي هيتم اتخاذها في اختيار الخاصية
- أول حاجة بيدخل كل الداتا و بيسأل هل هم لهم نفس الكلاس ولا لا
- لو اه يبقى خلاص ,, اما لو لا فيبدور على عمود او خاصية تانية و بيتم اختيارها بمعايير معينة تبع
- Attribute Selection method
- و بعد كده بيشوف فيه كام مسار هيمشى فيه تبع الخاصية دي و على قدرهم هيقسمهم
- Partitions
- و كل جزء من دول هيعمل فيه نفس اللي حصل لغيت اما كل الداتا تكون ليها كلاس



- The splitting criterion can cause one of 3 partitioning Scenario
 - Discrete eg..{Low , High , Middle}
 - Continuous -> in this case we use the logical operation eg {> , < , >= }
 - Binary Discrete {Yes or no}

Splitting Criterion is a test

- Which attribute to test at node N → What is the “best” way to partition D into mutually exclusive classes
- ايه افضل عمود استخدمه انه يفصل البيانات لمجوعات منفصلة غير مترابطة
- which (and how many) branches to grow from node N to represent the test outcomes
- Resulting partitions at each branch should be as “pure” as possible
- A partition is “pure” if all its tuples belong to the same class
- When attribute is chosen to split training data set, it's removed from attribute list

Terminating conditions

- 3 حالات بتظهر بعد عملية التصنيف
- All the tuples in D (represented at node N) belong to the same class
 - كل الداتا تاخذ نفس الكلاس اللي تتبع النقطة يبقى ما فيش تقسيم و انتهى
- There are no remaining attributes on which the tuples may be further partitioned
 - لو خالص مجموعة الخصائص اللي انت بتصنف من خلالها بتصنفهم تبع الاكثر الاكثر شيوعا
 - majority voting is employed → convert node into a leaf and label it with the most common class in data partition
- There are no tuples for a given branch
 - a leaf is created with the majority class in data partition

Attribute selection measure

a **heuristic** for selecting the splitting criterion that “best” splits a given data partition into smaller mutually exclusive classes

- دى طرق عشان نعرف بيها اى خاصية او عمود هنختاره بالترتيب عشان نعمل التصنيف في اقل عدد من الكلاس الغير متداخلين
- Attributes are ranked according to a measure
 - attribute having the best score is chosen as the splitting attribute
 - split-point for continuous attributes
 - splitting subset for discrete attributes with binary trees
- Measures: **Information Gain, Gain Ratio, Gini Index**

Information Gain

Based on **Shannon's information theory** 'Goal is to minimize the expected number of tests needed to classify a tuple

- guarantee that a simple tree is found 'Attribute with the highest information gain is chosen as the splitting attribute
- ال information gain بتحاول ان هي تلاقى ابسط tree ممكنة عن طريق تقليل كمية المعلومات اللي بنحتاجها عشان ن classify
- minimizes information needed to classify tuples in resulting partitions
- reflects **least “impurity”** in resulting partitions
- Given m class labels (C_i , $i = 1$ to m)
- Expected Information needed to classify a tuple in D
- $\text{Info}(D) = \text{entropy} = - \sum_{i=1}^m p_i \log_2(p_i)$
- $p_i \rightarrow$ probability that an arbitrary tuple in D belong to class C_i

$$p_i = \frac{|C_i D|}{|D|}$$

- $C_i, D \rightarrow$ set of tuples having class label C_i in partition D

Shanon Theory ?
 شانون بدأ بقياس المعلومات من خلال ال Entropy والاحتمالات

$$Entropy = H = - \sum p_i \log p_i$$

أما ال Expected Info التي تحتاجها عينات تقدر تصنف ال tuple
 من ال data وانت تعمل Partitioning لل A بواسطة Attribute (A)

$$info_A(D) = \sum_{j=1}^r \frac{|D_j|}{|D|} \times info(D_j)$$

وبالتالي كل ما كانت ال Expected info قليلة ~~يبقى ما بقي~~ كلما كانت
 ال Classes تكون أكثر independence وبالتالي صيدك أفضل Purity

$$Gain(A) = info(D) - info_A(D)$$

وبانت عايز تحافظ على كمية المعلومات التي في ال data ~~يبقى ما بقي~~
 على أقل فينس ممكنة ال Expected info $\leftarrow info_A(D)$

department	age	salary	status	count
sales	Middle aged	medium	senior	30
sales	youth	low	junior	30
sales	Middle aged	low	junior	40
systems	youth	medium	junior	20
systems	Middle aged	high	senior	20
systems	senior	high	senior	10
marketing	senior	medium	senior	10
marketing	Middle aged	medium	junior	20
secretary	senior	medium	senior	10
secretary	youth	low	junior	10

ال Status هو ~~Attribute~~ الفاصلة التي عايزين نضيقها في Class label

أدلة حاجة محتاجين نضيق ال Expected Info و ال Entropy

$$C_1 (\text{Senior}) = 80, C_2 (\text{Junior}) = 120$$

$$\text{Info}(D) = E = H = - \sum p_i \log p_i$$

$$= - \left(\frac{80}{200} \log \frac{80}{200} + \frac{120}{200} \log \frac{120}{200} \right)$$

$$= 0.97$$

أدلة محتاجين نضيق ال Expected info لكل Attribute من A-List

Department : Sales = 100 , System = 50
marketing = 30 , secretary = 20

$$Info_{dept} = \sum_{i=1}^n \frac{|D_i|}{|D|} \times \ln \left(\frac{|D|}{|D_i|} \right)$$

$$= \frac{100}{200} \times - \left(\overset{\text{senior}}{\frac{30}{100}} \log \frac{30}{100} + \frac{20}{100} \times \log \frac{20}{100} \right) +$$

$$\frac{50}{200} \times - \left(\frac{30}{50} \log \frac{30}{50} + \frac{20}{50} \times \log \frac{20}{50} \right) +$$

$$\frac{30}{200} \times - \left(\frac{10}{30} \log \frac{10}{30} + \frac{20}{30} \times \log \frac{20}{30} \right) +$$

$$\frac{20}{200} \times - \left(2 \times \frac{10}{20} \log \frac{10}{20} \right) = 0,92$$

Salary , age و منصب كات ينفى الطريقة لـ

$$Info_{age} = 0,55$$

$$Info_{salary} = 0,95$$

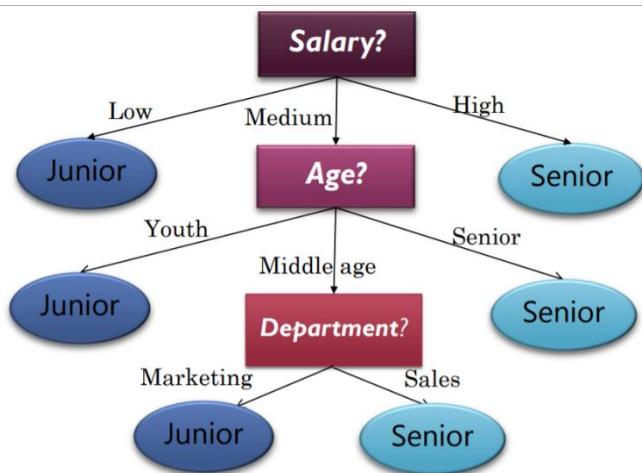
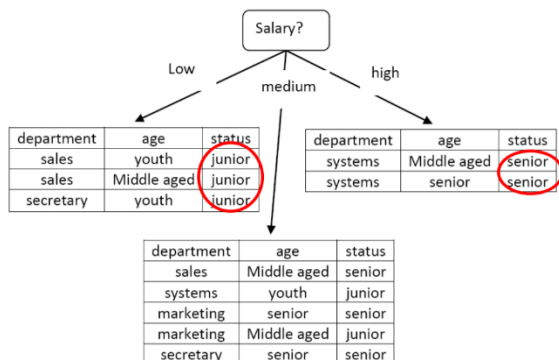
و حسب اد Gain لـ (3)

$$Gain(department) = 0,97 - 0,92 = 0,05$$

$$Gain(age) = 0,97 - 0,55 = 0,42$$

$$Gain(salary) = 0,97 - 0,95 = 0,02$$

که از Splitting Criterion به طرف ال Salary
و بعد که age ولو فاصد یقی ال department




- أول حاجة اما نبدا Classification نحدد أولا ال salary بتكون discrete و لها 3 Partitions
- نبدا نقسم الداتا على ال Classes دى هنلاقى ان مازال ال Medium partition مالهوش pure class
- نبدا نأخذ تانى criterion عشان ن classify من خلاله
- و هكذا لغيت أما الاقى ال Termination
- point لكل الداتا لو انت عندك continuous Attribute بنحاول نجيب ال midpoint عشان نحوله شبه ال discrete و بنسمى النقطة دى ال Split Point

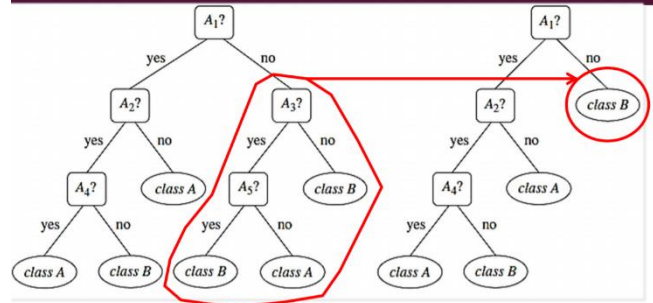
Information gain for **continuous attributes**

1. Sort values in increasing order
2. Each **midpoint** between two adjacent values can serve as **split-point**
3. Split-point between two values v_i and $v_{i+1} = \frac{v_i + v_{i+1}}{2}$
4. For each split-point, evaluate $info_A(D)$ with the number of partitions = 2 ($A \leq \text{split-point} \ \& \ A > \text{split-point}$)

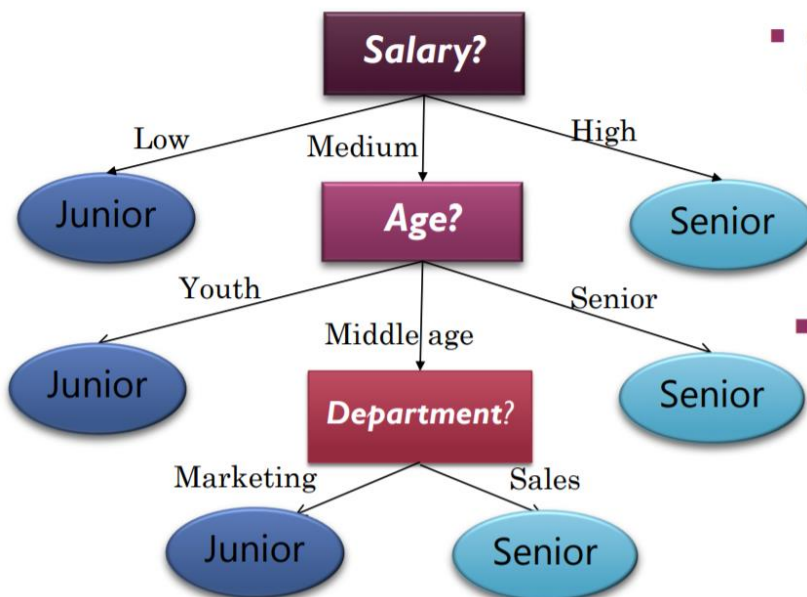
Tree Pruning



- تخيل ان عندك 2 class labels {Red & Blue} و لقيت ان وانت بت classify data ان معظما ال partition هيطلع أغلب الداتا ب Class {Blue} و احتمالية بسيطة جدا ان هو يبقى الكلاس التاني و المشكلة دي اسمها ال overfitting ,, فبذل ما أرهق الوقت و المجهود هقول ان ال partition ده الكلاس بتاعه Blue و هعمل pruning لل branches الزيادة دي
- زى الشكل اللي في الجنب ال overfitting هو اني اخلى ال tree بتاعتي تكون بدقة الخط الأخضر بس هيستغرق وقت و مجهود و منكم يخسر ,, فلو عملنا pruning منطقي هيبقى زى الخط الاسود



- Data may be **overfitted** to dataset anomalies and outliers
- Pruning removes the least reliable branches
- DT becomes less complex'
- Prepruning → statistically assess the goodness of a split before it takes place
 - hard to choose thresholds for statistical significance
- Postpruning → remove sub-trees from already constructed trees
 - remove sub-tree branches and replace with leaf node
 - leaf is labeled with most frequent class in sub-tree



- Create one rule for each path from root to leaf in the decision tree
 1. Each splitting criterion is ANDed to form rule antecedent (IF)
 2. Leaf node holds class prediction (THEN)
- R1: IF salary =medium AND age = youth THEN Status = Junior

Can the rules resulting from decision trees have conflicts?

RULE EXTRACTION FROM A DECISION TREE

department	age	salary	status	count
sales	Middle aged	medium	senior	30
sales	youth	low	junior	30
sales	Middle aged	low	junior	40
systems	youth	medium	junior	20
systems	Middle aged	high	senior	20
systems	senior	high	senior	10
marketing	senior	medium	senior	10
marketing	Middle aged	medium	junior	20
secretary	senior	medium	senior	10
secretary	youth	low	junior	10

Data item Belong To (medium) Partition

R_1 = If (Salary) = medium AND (age) = youth
Then (Status) = Junior

and youth

Class label

Rule

الخاصة بال Rule يتطابق !

$$\text{Coverage}(R) = \frac{n_{\text{Covered}}}{|D|} = \frac{20}{200} = 10\%$$

$$\text{accuracy}(R) = \frac{n_{\text{Correct}}}{n_{\text{Covered}}} = \frac{20}{20} = 100\%$$

Prediction Rule

لوحالي ent - بالشيء ده

X: (Department = System, age = youth,
Salary = medium)

Prediction of A Tree = Junior
for X

أحيانا يحصل مشكلة واختناق في ال Tree و Rule Conflict
ان يكون فيه Tuple يتحقق أكثر من قاعدة داخل ال Tree

الحل

2 Resolution strategies

SIZE
Ordering

معتمد على حجم ال Table الى موصولة
تبع ال Rule كلما كان اكبر حجم
مختار ال Rule

Rule
Ordering

Priority for Apriori

→ Class based ordering → decreasing importance

~~الطريقة~~ اول طريقة ترتيب عن طريق ال Class كل

ما كان ال Class ظهوره اكبر وإحتماله يبقى اختياره الأول

→ Rule-based ordering

وهنا يجب ال Accuracy ان Rule الى أعلى accuracy يتخذ

Fall back Rule

بعض ال default في ال Switch

لو مالفاشي Rule فيستخدمه

Naïve Bayesian Classifier

هو method د classification طريقة Statistical عن طريق

تنبؤ احتمالات ال Tuple ينتمي إلى الكلاس البين

High accuracy \Rightarrow دقة جداً
and Speed وسرعة

مبنى على Bayes Theory مبنى على مبدأ
(Class - Conditional Independence) }
و Attribute بتأثر الزاى فى تصنيف ال Tuple

$n = \# \text{ Attributes}$

$m = \# \text{ Classes}$

Naïve Bayes بيتنبأ ان ال Tuple لا ينتمى ل Class الى هو اعلو احتمال

$$P(C_i | x) > P(C_j | x) \text{ for } 1 \leq j \leq m, j \neq i$$

\Rightarrow Conditional Probability

$C_i \Rightarrow$ maximum Posteriori Hypothesis

$$P(C_i | x) = \frac{P(x | C_i) P(C_i)}{P(x)}$$

ار $P(x)$ ثابت يبقى احنا نكسر ن maximize البسط (numerator)

وتخيل ان احنا نعالج على Uniform Probability يبقى كما كمان

$P(C_i)$ مبقى موحدة دك القيم i

نکہہ انت مشی محتاج الا انلے maximize قیہ $P(X|C_i)$

لو مشی uniform $\Leftarrow \frac{|C_i|}{|D|}$ و $P(C_i)$

و عشات \Leftarrow Reduce Compute $P(X|C_i)$ منفرضات

Independent Attributes

$$P(X|C_i) = \prod_{k=1}^n P(x_k | C_i) = P(x_1 | C_i) \times P(x_2 | C_i) \times \dots \times P(x_n | C_i)$$

لوال \Leftarrow Attribute نوعه nominal Categorical

$$P(x_k | C_i) = \frac{|C_{ik}|}{|C_i|}$$

ایمالوکت \Leftarrow numerical Gaussian Distribution

$$P(x_k | C_i) = \frac{1}{\sqrt{2\pi}\sigma_{C_i}} e^{-\frac{(x_k - \mu_{C_i})^2}{2\sigma_{C_i}^2}}$$

department	age	salary	status	count
sales	Middle aged	medium	senior	30
sales	youth	low	junior	30
sales	Middle aged	low	junior	40
systems	youth	medium	junior	20
systems	Middle aged	high	senior	20
systems	senior	high	senior	10
marketing	senior	medium	senior	10
marketing	Middle aged	medium	junior	20
secretary	senior	medium	senior	10
secretary	youth	low	junior	10

X: { department="marketing", age="youth", salary="low" } ← object مثلاً

← 2 class labels

Senior
↓
دقيقه محتاجين نجيب

$$\textcircled{1} P(X|C_1) = \frac{10}{80} \times \frac{0}{80} \times \frac{0}{80} = 0 \rightarrow$$

$$\therefore P(X|C_1) P(C_1) = 0$$

Junior

$$\textcircled{2} P(X|C_2) = \frac{20}{120} \times \frac{60}{120} \times \frac{80}{120} = 0,055$$

$$\therefore P(X|C_2) P(C_2) = 0,055 \times \frac{120}{200} = 0,033$$

يبقى الـ X المجهول بينتقن لـ $Junior$

بـ فيه مشكلة! نـ لو فيه Attribute ماحققش يعني احتمال ظهور الـ X ما يعتمدش عليه كده فيحصل كذا الحالة (مفتر)

وعشان كده بيستخدم Laplace estimator Correction

ان بخواص ~~بـ~~ بقيمة (1) مكات الاضافي

$$P(X|C_1) = \frac{10}{80} + \frac{1}{80} + \frac{1}{80} = 0,0002$$

$$\therefore P(X|C_1) P(C_1) = 0,00008$$

$X_{class} = Junior$ و في كذا الحالة بيت

Lazy Learners

هم مجموعة Algorithms التي لا تعمل أو لا تعمل
على ما يتبعه models في Pattern على Learning Data
التي لها زمنية
داتا جديدة عابرة يحصل لها Classify

K-NEAREST Neighbor Class

يستخدم ال (Similarity measure) عشاق تحسب البعد ما بين
ال Test Data وال Data ال (Training)

ملحوظة إذا كانت ال Attributes مختلفة عن ال Ranges

عمل Normalization \Rightarrow Preprocessing

كل عدد ال neighbour objects الأقرب لل Test objects من خلال
ال distance

و بعمل عملية ال (majority Voting) عشاق تعرف
ال Class لل Test Data

Distance = Euclidean Distance

$$D = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$$

مثال

for $X \Rightarrow$ Test Data
and $Y \Rightarrow$ RID(1)

$$D_{X,Y} = \sqrt{(48 - 25)^2 + (142000 - 40000)^2}$$

$$= 102,000$$

و کذا
بسیار مشکلی است که این Loan نیاز به نرمالیزه

RID	age	Loan (\$)	Default	Distance
1	25	40000	No	102000
2	35	60000	No	82000
3	45	80000	No	62000
4	20	20000	No	122000
5	35	120000	No	22000
6	52	18000	No	124000
7	23	95000	Yes	47000
8	40	62000	Yes	80000
9	60	100000	Yes	42000
10	48	220000	Yes	78000
11	33	150000	Yes	8000
48	142000	?	fair	

و به سبب این که Distance به عمل Normalization

Preprocessing (Transfer) \Leftarrow [Min-max or Z-Score]

$$\text{Loan}_{\min} = 18000$$

$$\text{Loan}_{\max} = 220000$$

$$\text{Loan}_{\text{Proj}} = \frac{40000 - 18000}{220000 - 18000} \times (60 - 20) + 20$$

و کذا Distance

و به سبب این که Norm

$$\text{new-min} = 20 \quad \text{new-max} = 60$$

عملیات را در R و Python

Loan , Distance , age

Loan (\$)	Distance
24.4	30.6
28.3	20.8
32.3	12.7
20.4	37.0
40.2	13.7
20.0	24.9
35.2	26.7
28.7	17.8
36.2	14.6
60.0	15.4
46.1	15.1
44.6	

نحسب فيه آخره object لا Test
مطلوب

(No) $\Leftarrow K=1$ NR is RID 3

$K=3$ NR is RID (3 = No, 5 = No, 9 = Yes)

majority?

Default = No

```
Terminal Help Z-Score.ipynb - DataScience.Learning - Visual Studio Code
LICENSE Z-Score.ipynb x
Jupyter Server: local
[13] In: 13
n_loans = []
loans = np.array([40000, 60000, 80000, 20000, 120000, 18000, 95000, 62000,
100000, 220000, 150000])
for x in loans:
    n_loans.append((x-x_min)/(x_max-x_min)*(60-20)+20)
n_loans
```

Linear Regression

من أحد الطرق التي تعمل عليها Prediction

2 Variable Self Relationship

والنتيجة بتاعت ال Regression هي (Linear Regression equation)

أنت من خلال Variable أقدر تعمل Prediction Variable
التاني

$$Y = a + bX$$

بمعادله ان تكون (Scatter Plot) وبشوف أودر بغير إذا

كان الداتا fit a line goodly لأن لو مش متغيرة

للخط يعني ال Regression ما لو حست لزوم ←

2 Variable are Independent

~~$$Y = a + bx$$~~

$$Y = a + bx$$

$Y \Rightarrow$ dependent Variable

$X \Rightarrow$ independent Variable

$b \Rightarrow$ Slope

$a \Rightarrow$ y-intercept

(Σy , Σx^2 , Σy^2) حساب

$$a = \frac{(\Sigma y)(\Sigma x^2) - (\Sigma x)(\Sigma xy)}{n(\Sigma x^2) - (\Sigma x)^2}$$

$$b = \frac{n(\Sigma xy) - (\Sigma x)(\Sigma y)}{n(\Sigma x^2) - (\Sigma x)^2}$$

بعد الحساب

SUBJECT	AGE X	GLUCOSE LEVEL Y	XY	X ²	Y ²
1	43	99	4257	1849	9801
2	21	65	1365	441	4225
3	25	79	1975	625	6241
4	42	75	3150	1764	5625
5	57	87	4959	3249	7569
6	59	81	4779	3481	6561
Σ	247	486	20485	11409	40022

$$a = 65.1416$$

$$b = 0.395225$$

$$Y = 65.1416 + 0.395225 X$$

و جب اہ قیستے ل (X) پہلے قیستے (Y)

Metrics for Evaluating Classifier Performance

! رأيت أقيس تقييمات Classifier (Performance) { Performance }

Parameters

TP : { True Positives }

و عدد ال objects ال وصلهم تصنيف صحيح
وكلمات لهم أهمية { Class of interest }

TN : { True Negatives }

ليس مالهوش أهمية أو عرضي في البحث

Positives { P } \Rightarrow لهم أهمية عن البحث

Negatives { N } مالهوش أهمية

FP { False Positives }
هم مالهوش أهمية عن البحث و ال Classifier أخطأ
في التصنيف

FN { False Negatives }
لهم أهمية عن البحث ليس ال Classifier أخطأ في
التصنيف

Measures

accuracy = recognition rate

$$= \frac{TP + TN}{P + N} = \frac{\text{كل اللي اصبحت صحيح
كل الال انا}}{}$$

error rate = misclassification rate

$$= \frac{FP + FN}{P + N} = \frac{\text{كل اللي اصبحت غلط
كل الال انا}}{}$$

Sensitivity = True Positive Rate

$$= \frac{TP}{P}$$

معدل النوع من الباتات
لا مخرج الى كل انواع من الال لم يصب

specificity = true negative rate

$$= \frac{TN}{N}$$

Precision

$$= \frac{TP}{TP + FP}$$

		Predicted		
Actual		Yes	No	Total
	Yes	TP	FN	P
	No	FP	TN	N
Total		\hat{P}	\hat{N}	P + N

Confusion Matrix

- ال confusion matrix من أهم الاشكال الى بتخلينا نقيس ال performance لل classifier
- الصفوف بتوضح ايه القيم الحقيقية اللي المفروض ال classifier لو هو مية في المية صحيح يطلعها
- الأعمدة بتوضح ايه القيم الفعلية اللي تتبأ بيها ال classifier

		Predicted			Recognition(%)
Actual		Yes	No	Total	
	Yes	6954	46	7000	TP/P = 99.34
	No	412	2588	3000	TN/N = 86.27
Total		7366	2634	10000	$\frac{TP+TN}{P+N} = 95.42$

Example Buys_Computer Confusion Matrix

Use sensitivity (TPs or recall) and specificity


		Predicted			Accuracy (%)
Actual		Yes	No	Total	
	Yes	90	210	300	30
	No	140	9560	9700	98.56
Total		230	9770	10000	96.4

Example Cancer Confusion Matrix

Use sensitivity (TPs or recall) and specificity

- صحيح ال Accuracy بتاعت ال cancer اعلى من ال computers بس بسبب التباين الجزرى اللي حصل لل Positives اللي من حيث sensitivity اللي مش كويسة لدى ال cancer أدت ان الاعتماد على ال classifier ده غلط

- **Holdout** → RANDOMLY allocate 2/3 of data for training and remaining 1/3 for testing
- **Random Subsampling** → Repeat holdout k times and take average accuracy



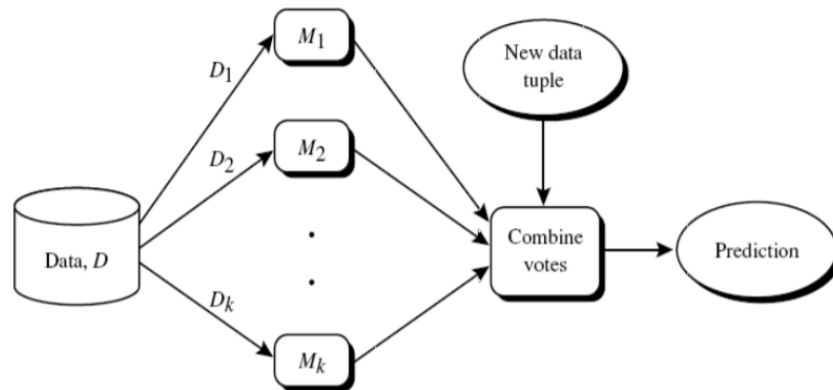
- من طريق تحسين عملية ال classification و هو اختيار ايه الداتا اللي هتعمل training و ايه اللي هتعمل بيه testing ففي ال holdout بقسم البيانات ل 3 أثلاث ,, ثلثان لل training و ثلث لل testing
- ال random subsampling انى اختبر الأقسام دى بعشوائية عدد من المرات لغيت ما أتأكد انه Balanced

- **k-fold cross-validation** → randomly partition dataset into k mutually exclusive **folds** of approximately equal size
- In iteration i , $fold_i$ is test set and all other folds are training set
- Accuracy = $\frac{\sum \text{correct classifications for all } k \text{ iterations}}{\text{dataset size}}$
- **Stratified k-fold cross-validation** → **class distribution** in each fold is approximately the same as in initial dataset
 - **Stratified 10-fold cross-validation** is recommended

- بعشوائية يحاول اقسام الداتا لمجموعة من ال folds الى تقريبا قد بعض
- و على قد ال folds و احدة منهم بتكون test و الباقي training
- ال stratified sampling ان في كل flod لازم يكون نسب ال classes بتساوى النسب الأصلية لل Whole dataset

○ **Ensemble** → a set of classifiers, each with a vote for a class label

- Each base classifier is produced from a different partition of the dataset
- Majority voting is used to compose an **aggregate classification**



- في ال ensemble يشتغل بأكثر من classifier و أخليهم يشتغلوا على الداتا و افارن بين النتائج بتاعتهم و أعمل aggregation لافضل نتيجة في ال accuracy لل classifier و اللي يطلع أفضل أختاره انه يبقى ال classifier بتاعى

Algorithm: Bagging. The bagging algorithm—create an ensemble of classification models for a learning scheme where each model gives an equally weighted prediction.

Input:

- D , a set of d training tuples;
- k , the number of models in the ensemble;
- a classification learning scheme (decision tree algorithm, naïve Bayesian, etc.).

Output: The ensemble—a composite model, M^* .

Method:

- (1) for $i = 1$ to k do // create k models:
- (2) create bootstrap sample D_i , by sampling D with replacement;
- (3) use D_i and the learning scheme to derive a model, M_i ;
- (4) endfor

To use the ensemble to classify a tuple, X :

let each of the k models classify X and return the majority vote;

Bootstrap

→ same size
as dataset,
sampling
with
replacement

3
5
3
7
4
3
7
9
6
10

- في ال Bagging يستخدم ال SRSWR Sampling بس Bootstrap يعنى من نفس المقاس لأنه ب replacement و بعملهم ensembling عادى و بفاضل بينهم